

# Introducción al aprendizaje profundo

---

Aprendizaje profundo

Departamento de Sistemas Informáticos

E.T.S.I. de Sistemas Informáticos - UPM



# Introducción

# ¿Dónde encaja el aprendizaje profundo?

---



**Figura 1.** El aprendizaje profundo es un subconjunto del aprendizaje automático, que es a su vez un subconjunto de la inteligencia artificial. Fuente [Geeks for Geeks](#)

# Inteligencia artificial (IA)

---

Campo de estudio que se ocupa de la creación de sistemas que pueden realizar tareas que requieren inteligencia humana

- Razonamiento, **aprendizaje**, percepción, toma de decisiones, ...
- Se aplica en prácticamente todo campo imaginable
  - Diagnóstico médico, robótica, vehículos autónomos, asistentes personales, sistemas de recomendación, automatización de procesos industriales, ...

Sigue evolucionando rápidamente impulsando la innovación tecnológica

- Lleva años revolucionando cómo interactuamos con el mundo digital y físico
- Plantea importantes cuestiones éticas y sociales
  - Privacidad de los datos, seguridad, desempleo, sesgos, interpretación de los modelos, ...

# Aprendizaje automático (ML, del inglés *machine learning*)

---

Técnicas que permiten a las máquinas extraer información (aprender) de los datos

- Se trata de un subconjunto de la IA, e implica un cambio de paradigma
  - En lugar de programar las reglas, se entrena un modelo con ejemplos
  - Estos modelos mejoran su desempeño con el tiempo, **sin ser explícitamente programadas para las tareas específicas**

¿Qué formas de aprendizaje existen?:

- **Aprendizaje supervisado:** Se entrena con ejemplos etiquetados
- **Aprendizaje no supervisado:** Se entrena con ejemplos no etiquetados
- **Aprendizaje por refuerzo:** Se entrena con un sistema de recompensas

# Aprendizaje supervisado

---

El modelo se alimenta con ejemplos de entradas y sus respectivas salidas

- Entradas: Características, atributos, variables independientes, ...
- Salidas: Etiquetas, resultados, variables dependientes, ...

Su objetivo es modelar la relación existente entre las entradas y las salidas

- El modelo aprende a predecir la salida de nuevos ejemplos no vistos previamente
- Los problemas son de dos tipos: **clasificación** y **regresión**
  - Que en esencia es predecir valores discretos o continuos, respectivamente

Estos modelos se evalúan según su capacidad para predecir **correctamente** las etiquetas de un conjunto de datos de prueba, no visto anteriormente

# Aprendizaje supervisado - Clasificación

Dadas unas características de entrada, queremos saber a qué clase pertenece




**Figura 2.** Esquema de tarea de clasificación.

Principalmente tres tipos: **binaria**, **multiclase** y **multietiqueta**

# Aprendizaje supervisado - Regresión

Dadas unas características de entrada, queremos predecir un valor continuo



**Figura 3.** Esquema de tarea de regresión.

El objetivo es encontrar una función que se ajuste a los datos de entrenamiento



# Aprendizaje no supervisado

---

El modelo se alimenta con ejemplos de entradas, pero **sin etiquetas**

- El objetivo es encontrar patrones, estructuras o relaciones en los datos
- Se utiliza para **agrupar** o **reducir la dimensionalidad** de los datos
- También para **recomendar** o **generar** nuevos datos

Los problemas más comunes son:

- **Clustering**: Agrupar los datos en función de sus características
- **Reducción de la dimensionalidad**: Reducir el número de características
- **Generación de datos sintéticos**: Crear nuevos datos a partir de los existentes

# Aprendizaje no supervisado - Clustering, dimensionalidad y generación



**Figura 4.** Un *autoencoder* es una de las técnicas usadas para clústering, reducción de dimensionalidad y generación de datos sintéticos. Fuente: Clustering of LMS Use Strategies with Autoencoders

# Aprendizaje por refuerzo

---

El modelo se alimenta con ejemplos de entradas, pero **no de salidas**

- Aprende a través de la interacción con el entorno
- El objetivo es maximizar una recompensa a lo largo del tiempo

Los modelos usan estados, acciones y recompensas para aprender

- Su objetivo es realizar acciones que nos lleven a estados con recompensas altas
  - Intentando que a largo plazo sea alta, aunque a corto plazo sea baja
  - Es el mismo concepto detrás de los juegos de mesa

Suele estar bastante presente en robótica, juegos y simulaciones

# Aprendizaje profundo (DL, del inglés *deep learning*)

---

Subcategoría del ML, inspirada en la estructura y función del cerebro humano

- Utiliza redes neuronales con muchas capas (profundas) para analizar grandes conjuntos de datos
- Ha impulsado avances significativos en áreas como el reconocimiento de voz e imagen, la traducción automática, la robótica, la medicina, ...

Las técnicas que componen este área:

- Tratan de aprender representaciones útiles y significativas de los datos
  - Las representaciones surgen de la combinación de múltiples capas de procesamiento
- Tratan de sacar conclusiones similares a las que sacarían los humanos

# Ideas clave en el aprendizaje profundo

---

El cerebro compara la información nueva con objetos conocidos

- Es el mismo concepto detrás de las redes neuronales artificiales (ANN)

Las capas de una red neuronal pueden considerarse *filtros*

- Estas capas se tienden a estructurar de granularidad más gruesa a más fina
- De esta manera existe mayor probabilidad obtener resultados correctos con mayor exactitud

En general, el DL puede hacer lo mismo que el ML

- Pero a la inversa no se cumple

# Más ideas clave

---

Prácticamente *todos* los últimos avances de la IA se deben al DL

- Está detrás de los servicios cotidianos (p.ej. asistentes digitales)
- También de tecnologías emergentes (p.ej. coches autónomos)
- Parece que estamos viviendo una nueva revolución industrial <sup>1</sup>

Prácticamente todos los modelos de DL utilizan ANN

- Por eso suelen denominarse redes neuronales profundas (DNN)
- El término *deep* se suele referir al número de capas ocultas
  - Tradicionales (*shallow*) → de 1 a 3 capas ocultas
  - Profundas (*deep*) → Más de 3, ¡incluso cientos!

---

<sup>1</sup> Al menos eso indican algunos autores, como con casi cualquier nueva tecnología.

**Un poquito de historia**

# Empezando desde el principio

---

- **1943:** Modelo de neurona artificial propuesto por McCulloch y Pitts
  - Un modelo electrónico que simula el comportamiento de una neurona
- **1949:** Donald Hebb propone Teoría Hebbiana<sup>2</sup>
  - Básicamente, las conexiones entre neuronas se fortalecen con el uso y la repetición
- **1958:** Frank Rosenblatt propone el perceptrón<sup>3</sup>
- **1969:** Un par de hitos interesantes:
  - Minsky y Papert publican *Perceptrons*<sup>4</sup>
    - Se demostró que las redes neuronales no servían para problemas no lineales y se abandonaron
  - Fukushima, K describe la función de activación ReLU, muy famosa muchos años después<sup>5</sup>

---

<sup>2</sup> Hebb, D. O. (2005). *The organization of behavior: A neuropsychological theory*. Psychology press.

<sup>3</sup> Rosenblatt, F. (1958). *The perceptron: a probabilistic model for information storage and organization in the brain*. Psychological review, 65(6), 386.

<sup>4</sup> Minsky, M. L., & Papert, S. A. (1969). *Perceptrons: An introduction to computational geometry*. MIT press.

<sup>5</sup> Fukushima, K. (1969). *Visual feature extraction by a multilayered network of analog threshold elements*. IEEE Transactions on Systems Science and Cybernetics, 5(4), 322-333.



# Resurgen las redes neuronales

---

- **1980:** Fukushima K. propone el neocognitron<sup>6</sup>
  - Modelo de red neuronal convolucional (CNN) inspirado en la corteza visual del cerebro
- **1986:** Rumelhart et al. describen el algoritmo de *back propagation*<sup>7</sup> para MLP
- **1989:** Se demuestra que un perceptrón multicapa (MLP) se comporta como **aproximador universal**<sup>8</sup>
  - Una única capa oculta es capaz de aproximar cualquier función continua de  $n$  variables
  - Pero **el número de parámetros puede terminar siendo extremadamente alto**
  - **Más capas** requieren **menos parámetros** y **aumentan** su capacidad de **generalización**
- **1998:** LeCun et al. aplican *back propagation* a redes convolucionales (CNN)

---

<sup>6</sup> Fukushima, K. (1980). *Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position*. Biological cybernetics, 36(4), 193-202.

<sup>7</sup> Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). *Learning representations by back-propagating errors*. nature, 323(6088), 533-536.

<sup>8</sup> Cybenko, G. (1989). *Approximation by superpositions of a sigmoidal function*. Mathematics of control, signals and systems, 2(4), 303-314.

# Comienza la era del aprendizaje profundo

---

- **2006:** G. Hinton acuña el término de *deep learning*<sup>9</sup>
- **2011:** IBM Watson gana en el concurso Jeopardy (markoff2011computer)
- **2012:** AlexNet gana el ImageNet, revolucionando el campo de la visión artificial<sup>10</sup>
  - A partir de este momento, **solo los algoritmos de DL ganan el concurso**
- **2014:** Facebook desarrolla DeepFace<sup>11</sup>; Google compra [DeepMind](#)
- **2015:** ResNet<sup>12</sup> supera al humano en el ImageNet Contest

---

<sup>9</sup> Hinton, G. E., & Salakhutdinov, R. R. (2006). *Reducing the dimensionality of data with neural networks*. science, 313(5786), 504-507..

Resolvieron el problema de *vanishing gradients* usando un proceso iterativo con *autoencoders* en las primeras capas.

<sup>10</sup> Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). *Imagenet classification with deep convolutional neural networks*. Advances in neural information processing systems, 25. Arquitectura de 8 capas con un **error del 15.3%**. El anterior ganador obtuvo un **26.2%** de error. El ser humano tiene un error aproximadamente el **5%**.

<sup>11</sup> Taigman, Y., Yang, M., Ranzato, M. A., & Wolf, L. (2014). *Deepface: Closing the gap to human-level performance in face verification*. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 1701-1708).

<sup>12</sup> He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep residual learning for image recognition*. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 770-778).

# La era contemporánea

---

- **2016:** **Alpha Go** (Google DeepMind) vence a Lee Sedol
  - Aprendizaje por refuerzo preentrenado con datos de humanos
- **2017:** **Alpha Go Zero** vence a Alpha Go
  - El salto es sustancial, ya que **no se preentrena con datos humanos**
- **2018:** **Alpha Star** vence al mejor jugador de Startcraft II
  - Su primera versión logró colarse entre el 0.2% de los mejores jugadores del mundo
- **2019:** **GPT-2** (OpenAI); modelo de lenguaje con 1.5 billones de parámetros
- **2021:** **DALL-E** (OpenAI); modelo de generación de imágenes a partir de texto
- **2023:** **MusicGen**; modelo de generación de música (basado en GPT-3)<sup>13</sup>
- **2024:** **SORA** (OpenAI); modelo de generación de video a partir de texto<sup>14</sup>

---

<sup>13</sup> Copet, Jade, et al. *Simple and controllable music generation*. *Advances in Neural Information Processing Systems*, 2024, vol. 36.; > Web <https://musicgen.com/> (último acceso 19 de febrero de 2024).

<sup>14</sup> Informe técnico: Video generation models as world simulators; Web: <https://openai.com/sora> (último acceso 19 de febrero de 2024).

**El porqué de su popularidad**

# Razones

---

En una palabra: **exactitud** (*accuracy*)

- El DL logra una precisión como nunca antes alcanzada
- Los modelos llegan a superar a los humanos en algunas tareas

Teorizado a mediados de los 1980, pero ahora es útil porque disponemos de:

1. Cantidades ingentes de datos y la posibilidad de almacenarlos
2. Acceso a una gran potencia de cálculo y técnicas para optimizarlo

Algunos autores y denominan **aprendizaje universal** al DL

- Se debe a que es una técnica útil para casi todos los campos de aplicación
- El **transfer learning** ayuda a esta concepción de la universalidad

# Preprocesamiento de datos (I)

---

El ML necesita de una fase de extracción e ingeniería de características

- El DL no, sólo requiere de la adaptación de los datos de entrada al modelo

Necesitamos preparar los datos para representarlos

- **Muy** complejo, requiere **mucho conocimiento del dominio**
- Proceso de ensayo y error para obtener resultados óptimos

En DL no es necesario un paso de preprocesamiento de datos

- El modelo aprende a representar los datos brutos por sí misma
- Cada capa aprende una representación cada vez más abstracta
- Se optimiza automáticamente durante el entrenamiento

# Preprocesamiento de datos (II)



**Figura 6.** Un proceso de aprendizaje automático requiere una fase de selección de características.



**Figura 7.** El aprendizaje profundo no requiere de dicha fase, ya que el propio modelo es capaz de inferir las características relevantes para el problema en cuestión.

# Big data

---

Los modelos de ML tradicional dejan de mejorar a partir de un punto

- **Punto de saturación**, donde la precisión ya no mejora añadiendo más datos

Los algoritmos de DL son menos sensibles al punto de saturación

- Añadir más datos tiende a producir una mejora en la exactitud (*accuracy*)
- En la era del **Big Data** es una gran ventaja
  - Nunca hemos tenido tantos datos disponibles ni tanta capacidad de cómputo como ahora

Los algoritmos de DL escalan en términos de datos y, sobre todo, de cómputo

- Por ejemplo, ResNet se implementó a escala de supercomputación
- Se ha demostrado que el DL puede escalar a cientos de miles de núcleos



# Big data



**Figura 7.** Relación entre capacidad de aprendizaje y volumen de datos en modelos estadísticos, de aprendizaje automático y de aprendizaje profundo (redes neuronales).

# Ventajas y desventajas del aprendizaje profundo

---

## Ventajas

- Capacidad de **aprender y adaptarse** (mejorar) de forma independiente
- **Aplicable** en casi cualquier campo y **sobre cualquier problema**
- **Superación de la capacidad humana** en tareas específicas
- **Revolución en múltiples sectores** (medicina, automoción, finanzas, etc.)

## Inconvenientes

- Necesidad de **muchos datos**
- Altísimo **coste computacional** y por tanto, **impacto medioambiental**
- Prácticamente **imposible interpretar o explicar** los modelos generados
- Riesgo de **perpetuación de sesgos existentes** en los datos de entrenamiento

# Areas de aplicación

# Áreas de aplicación del aprendizaje profundo

---

Hemos visto que al DL se le suele denominar «método de aprendizaje universal»

- Esto es porque es potencialmente aplicable a todos los campos
- De hecho **hoy en día se aplica a casi todos los campos conocidos**

Usados normalmente donde se requieren habilidades humanas

- Por ejemplo, la visión, reconocimiento del habla o del entorno
- Y no hay disponible un humano para realizar las tareas
  - O lo hay, pero sería tremendamente ineficiente ... o imposible

A continuación veremos algunos ejemplos de aplicaciones del DL



# Robótica (I)

---

Una de las áreas en las que el DL ha tenido más impacto

- Percepción de obstáculos y path planning inmediato
- Tareas de estabilidad y control<sup>15</sup>
- Robots industriales con visión artificial
- Apoyo a sistemas de mantenimiento predictivo
- Asistencia a la comunicación intra e inter-robot
- Robótica de servicio y asistencial

---

<sup>15</sup> Los robots de Boston Dynamics, hasta cayéndose lo hacen con estilo. Imagen extraída de <https://youtu.be/aX7KypGlitg> (The Independent)

# Robótica (II)

Los coches autónomos son una de las tecnologías en auge gracias al DL

- Detección y seguimiento de objetos alrededor del vehículo<sup>16</sup>
- Ubicación en la calzada
- Identificación de las señales de tráfico
- Análisis en tiempo real del estado del conductor o del vehículo
- Asistencia a la comunicación intra e inter-vehicular

<sup>16</sup> Imagen extraída de Zheng, Jingxiao, et al. *Multi-modal 3d human pose estimation with 2d weak supervision in autonomous driving*. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022. p. 4478-4487.



# Texto y lenguaje

---

El DL es ideal para las tareas de NLP

- Las herramientas que lo usan son órdenes de magnitud más avanzadas
- Aprovecha muy bien la habilidad del DL para extraer características

Algunas aplicaciones dentro del área incluyen:

- Entender la actitud de un actor mediante el análisis del lenguaje usado<sup>17</sup>
- Filtrado de información en función de parámetros sociales, geográficos, económicos y preferencias individuales<sup>18</sup>
- Generación de texto en lenguaje natural desde información no estructurada<sup>19</sup>

---

<sup>17</sup> Ejemplo: <https://monkeylearn.com/sentiment-analysis-online/>

<sup>18</sup> Ejemplo: <https://www.facebook.com/Engineering/videos/10154132641047200>

<sup>19</sup> Ejemplos: <https://play.aidungeon.io>, <https://www.projectelectricsheep.com/> o <https://www.usetopic.com/blog-idea-generator>



# Visión artificial

---

El *deep learning* permite el reconocimiento visual de imágenes a gran escala

- Abstrae prácticamente todo esfuerzo manual en el proceso
- Permite identificar características en grandes conjuntos de datos
- En definitiva, está impulsando el crecimiento de muchas áreas
  - Es esencial en todo sistema que requiera visión (p.ej. coches autónomos)
  - Segmentación de tumores cerebrales<sup>20</sup>
  - Sistemas de reconocimiento de expresión facial<sup>21</sup>
  - Reconocimiento biométrico a través del iris del ojo. Deeplris<sup>22</sup>

---

<sup>20</sup> Ranjbarzadeh, Ramin, et al. *Brain tumor segmentation of MRI images: A comprehensive review on the application of artificial intelligence tools*. *Computers in biology and medicine*, 2023, vol. 152, p. 106405.

<sup>21</sup> Hassan, Syed Muhammad, et al. *An Effective Combination of Textures and Wavelet Features for Facial Expression Recognition*. *Engineering, Technology & Applied Science Research*, 2021, vol. 11, no 3, p. 7172-7176.

<sup>22</sup> Tamizhiniyan, S. R., et al. *Deeplris: An ensemble approach to defending Iris recognition classifiers against Adversarial Attacks*. *En 2021 International Conference on Computer Communication and Informatics (ICCCI)*. IEEE, 2021. p. 1-8.



# Asistentes virtuales

---

Son aplicaciones que entienden los comandos en lenguaje natural

- Amazon Alexa, Cortana, Siri, Google Assistant, ...
- Personalizan la experiencia de usuario en base al histórico
- Aprenden con cada interacción, sobre todo en reconocimiento
- Otras capacidades: Traducción de discurso a texto, toma de notas, gestión de citas

Los *chatbot* (p.ej. ChatGPT) son asistentes virtuales específicos para chatear

- Interacción con clientes y marketing en las redes sociales
- Ofrecen atención al cliente inmediata y personalizada
- Algunos ejemplos:
  - [Andy Robot](#), *chatbot* para aprender inglés en Telegram
  - Alerta de Salud de la OMS: WhatsApp al +41 797 818 791 con 'Hi'

# Salud

---

Una de las mayores tendencias actuales es en el área de la salud<sup>23</sup>

- En el área de la atención sanitaria
  - Ayuda al diagnóstico por rayos X (waheed2020covidgan,narin2021automatic)
  - Análisis en tiempo real de datos agregados de sensores (philip2021deep)
  - Diagnósticos y tratamientos personalizados por paciente (oh2021deep)
  - Identificación de trastornos del desarrollo como el autismo~ (heinsfeld2018identification)
- En el área farmacéutica
  - Descubrimiento de fármacos (predicción de sus efectos) (gawehn2016deep,chen2018rise)

---

<sup>23</sup> Piccialli, Francesco, et al. Artificial intelligence and healthcare: Forecasting of medical bookings through multi-source time-series fusion. Information Fusion, 2021, vol. 74, p. 1-16.

# Generación de contenido

---

Otra de las áreas es la modificación o generación total de contenido

- [WaveNet](#) analiza y sintetiza señales de audio similares (oord2016wavenet)
- AutoFoley crea efectos de audio a partir de vídeos mudos (ghose2020autofoley)
- [NeuralFunk](#) genera pistas de audio de longitud indefinida
- Generación de rostros realistas pero inexistentes (karras2017progressive)
- Generación de los momentos más destacados en competiciones, p.ej. Wimbledon (merler2018automatic)
- Vídeos e imágenes «ultrafalsas» (thies2016face2face)
- [DeepDream](#) genera imágenes psicodélicas a partir de su conocimiento

# Y muchas más áreas

---

- Ciberseguridad
- Realidad virtual y aumentada
- Simulación y videojuegos
- Ciencias sociales
- Finanzas y bolsa

# Limitaciones y retos

# Limitaciones y retos de los modelos de *deep learning* (I)

---

## Los requisitos de hardware

- Los modelos requieren cada vez más memoria y capacidad de cómputo
- Las GPU y TPU son muy caras, además del impacto energético y medioambiental

## Los modelos más potentes usan cada vez más parámetros

- Esto es, cada vez conjuntos de datos más grandes, que no siempre tenemos
- A veces se emplean en datos sintéticos, pero no siempre es válido usarlos

## Los modelos, una vez entrenados, se vuelve inflexibles

- Soluciones eficientes, pero para problemas concretos
- Es muy típico que un problema similar requiera de un nuevo entrenamiento

# Limitaciones y retos de los modelos de *deep learning* (II)

---

Los modelos de *deep learning* aprenden mediante observaciones

- Solo saben lo que existe en los datos con los que se ha entrenado
- Una muestra no representativa hace que el modelo no generalice

Los datos suelen estar sesgados (consciente o inconscientemente)

- Si existen sesgos en los datos, existirán en las predicciones
- Los modelos aprenden a partir de variaciones que, a veces, no son explícitas
- Una decisión errónea/poco ética puede impactar negativamente en el mundo real
- No existe (por ahora) forma clara de explicar el razonamiento tras cada predicción
  - La imposibilidad de explicación hace todavía más difícil detectar estos problemas de sesgo

**Inteligencia artificial explicable (XAI, del inglés *explainable AI*)**



# ¿Cuál es el problema de la XAI?

---

Los modelos funcionan como una caja negra

- Aprenden relaciones y razonan a través de ellas
- Estas tienen poco o nada que ver con el razonamiento humano
  - No entraremos en el debate de si este es o no simbólico
- Aun errónea, no sabríamos el porqué ni cómo contraargumentar una decisión

Estas decisiones pueden tener un **impacto social o medioambiental**

- Diagnóstico médico donde se determina una enfermedad
- Concesión o no de un crédito en función de ciertos parámetros
- Emisión de veredictos judiciales
- Frenar o no ante humanos en un paso de peatones

# Sobre la inteligencia artificial explicable

---

Es el conjunto de técnicas y métodos para explicar las decisiones de algoritmos de IA, teniendo en cuenta:

1. Naturaleza del modelo, que comprende dos extremos
  - Modelos totalmente transparentes como los árboles de decisión
  - Modelos de caja negra como Artificial Neural Network (ANN)
2. Público objetivo, que afecta en dos dimensiones diferentes
  - Nivel de detalle
  - Forma de presentación

# Conclusiones

# Conclusiones

---

El aprendizaje profundo se utiliza extensivamente en la industria

- Cada vez más organizaciones lo están adoptando para seguir siendo competitivas

En la última década ha habido un gran avance en el DL, principalmente por:

- La amplia disponibilidad del *big data*,
- La potencia computacional, y
- Nuevas técnicas que han mejorado los modelos convencionales en varios órdenes de magnitud

Aun así, hay muchas aplicaciones a las que no se debería delegar las decisiones debido a su potencial impacto en la vida de las personas

# Licencia

Esta obra está licenciada bajo una licencia **Creative Commons  
Atribución-NoComercial-CompartirIgual 4.0 Internacional**.

Puedes encontrar su código en el siguiente enlace:  
<https://github.com/blazaid/aprendizaje-profundo>