

Introducción al aprendizaje profundo

Aprendizaje profundo

Departamento de Sistemas Informáticos

E.T.S.I. de Sistemas Informáticos - UPM



Introducción

¿Dónde encaja el aprendizaje profundo?



Figura 1. El aprendizaje profundo es un subconjunto del aprendizaje automático, que es a su vez un subconjunto de la inteligencia artificial. Fuente [Geeks for Geeks](#)

Inteligencia artificial (IA)

Campo de estudio que se ocupa de la creación de sistemas que pueden realizar tareas que requieren inteligencia humana

- Razonamiento, **aprendizaje**, percepción, toma de decisiones, ...
- Se aplica en prácticamente todo campo imaginable
 - Diagnóstico médico, robótica, vehículos autónomos, asistentes personales, sistemas de recomendación, automatización de procesos industriales, ...

Sigue evolucionando rápidamente impulsando la innovación tecnológica

- Lleva años revolucionando cómo interactuamos con el mundo digital y físico
- Plantea importantes cuestiones éticas y sociales
 - Privacidad de los datos, seguridad, desempleo, sesgos, interpretación de los modelos, ...

Aprendizaje automático (ML, del inglés *machine learning*)

Técnicas que permiten a las máquinas extraer información (aprender) de los datos

- Se trata de un subconjunto de la IA, e implica un cambio de paradigma
 - En lugar de programar las reglas, se entrena un modelo con ejemplos
 - Estos modelos mejoran su desempeño con el tiempo, **sin ser explícitamente programadas para las tareas específicas**

¿Qué formas de aprendizaje existen?:

- **Aprendizaje supervisado:** Se entrena con ejemplos etiquetados
- **Aprendizaje no supervisado:** Se entrena con ejemplos no etiquetados
- **Aprendizaje por refuerzo:** Se entrena con un sistema de recompensas

Aprendizaje supervisado

El modelo se alimenta con ejemplos de entradas y sus respectivas salidas

- Entradas: Características, atributos, variables independientes, ...
- Salidas: Etiquetas, resultados, variables dependientes, ...

Su objetivo es modelar la relación existente entre las entradas y las salidas

- El modelo aprende a predecir la salida de nuevos ejemplos no vistos previamente
- Los problemas son de dos tipos: **clasificación** y **regresión**
 - Que en esencia es predecir valores discretos o continuos, respectivamente

Estos modelos se evalúan según su capacidad para predecir **correctamente** las etiquetas de un conjunto de datos de prueba, no visto anteriormente

Aprendizaje supervisado - Clasificación

Dadas unas características de entrada, queremos saber a qué clase pertenece



Figura 2. Esquema de tarea de clasificación.

Principalmente tres tipos: **binaria**, **multiclase** y **multietiqueta**

Aprendizaje supervisado - Regresión

Dadas unas características de entrada, queremos predecir un valor continuo



Figura 3. Esquema de tarea de regresión.

El objetivo es encontrar una función que se ajuste a los datos de entrenamiento

Aprendizaje no supervisado

El modelo se alimenta con ejemplos de entradas, pero **sin etiquetas**

- El objetivo es encontrar patrones, estructuras o relaciones en los datos
- Se utiliza para **agrupar** o **reducir la dimensionalidad** de los datos
- También para **recomendar** o **generar** nuevos datos

Los problemas más comunes son:

- **Clustering**: Agrupar los datos en función de sus características
- **Reducción de la dimensionalidad**: Reducir el número de características
- **Generación de datos sintéticos**: Crear nuevos datos a partir de los existentes

Aprendizaje no supervisado - Clustering, dimensionalidad y generación



Figura 4. Un *autoencoder* es una de las técnicas usadas para clústering, reducción de dimensionalidad y generación de datos sintéticos. Fuente: Clustering of LMS Use Strategies with Autoencoders

Aprendizaje por refuerzo

El modelo se alimenta con ejemplos de entradas, pero **no de salidas**

- Aprende a través de la interacción con el entorno
- El objetivo es maximizar una recompensa a lo largo del tiempo

Los modelos usan estados, acciones y recompensas para aprender

- Su objetivo es realizar acciones que nos lleven a estados con recompensas altas
 - Intentando que a largo plazo sea alta, aunque a corto plazo sea baja
 - Es el mismo concepto detrás de los juegos de mesa

Suele estar bastante presente en robótica, juegos y simulaciones

Aprendizaje profundo (DL, del inglés *deep learning*)

Subcategoría del ML, inspirada en la estructura y función del cerebro humano

- Utiliza redes neuronales con muchas capas (profundas) para analizar grandes conjuntos de datos
- Ha impulsado avances significativos en áreas como el reconocimiento de voz e imagen, la traducción automática, la robótica, la medicina, ...

Las técnicas que componen este área:

- Tratan de aprender representaciones útiles y significativas de los datos
 - Las representaciones surgen de la combinación de múltiples capas de procesamiento
- Tratan de sacar conclusiones similares a las que sacarían los humanos

Ideas clave en el aprendizaje profundo

El cerebro compara la información nueva con objetos conocidos

- Es el mismo concepto detrás de las redes neuronales artificiales (ANN)

Las capas de una red neuronal pueden considerarse *filtros*

- Estas capas se tienden a estructurar de granularidad más gruesa a más fina
- De esta manera existe mayor probabilidad obtener resultados correctos con mayor exactitud

En general, el DL puede hacer lo mismo que el ML

- Pero a la inversa no se cumple

Más ideas clave

Prácticamente *todos* los últimos avances de la IA se deben al DL

- Está detrás de los servicios cotidianos (p.ej. asistentes digitales)
- También de tecnologías emergentes (p.ej. coches autónomos)
- Parece que estamos viviendo una nueva revolución industrial ¹

Prácticamente todos los modelos de DL utilizan ANN

- Por eso suelen denominarse redes neuronales profundas (DNN)
- El término *deep* se suele referir al número de capas ocultas
 - Tradicionales (*shallow*) → de 1 a 3 capas ocultas
 - Profundas (*deep*) → Más de 3, ¡incluso cientos!

¹ Al menos eso indican algunos autores, como con casi cualquier nueva tecnología.

Un poquito de historia

Empezando desde el principio

- **1943:** Modelo de neurona artificial propuesto por McCulloch y Pitts
 - Un modelo electrónico que simula el comportamiento de una neurona
- **1949:** Donald Hebb propone Teoría Hebbiana²
 - Básicamente, las conexiones entre neuronas se fortalecen con el uso y la repetición
- **1958:** Frank Rosenblatt propone el perceptrón³
- **1969:** Un par de hitos interesantes:
 - Minsky y Papert publican *Perceptrons*⁴
 - Se demostró que las redes neuronales no servían para problemas no lineales y se abandonaron
 - Fukushima, K describe la función de activación ReLU, muy famosa muchos años después⁵

² Hebb, D. O. (2005). *The organization of behavior: A neuropsychological theory*. Psychology press.

³ Rosenblatt, F. (1958). *The perceptron: a probabilistic model for information storage and organization in the brain*. Psychological review, 65(6), 386.

⁴ Minsky, M. L., & Papert, S. A. (1969). *Perceptrons: An introduction to computational geometry*. MIT press.

⁵ Fukushima, K. (1969). *Visual feature extraction by a multilayered network of analog threshold elements*. IEEE Transactions on Systems Science and Cybernetics, 5(4), 322-333.

Resurgen las redes neuronales

- **1980:** Fukushima K. propone el neocognitron⁶
 - Modelo de red neuronal convolucional (CNN) inspirado en la corteza visual del cerebro
- **1986:** Rumelhart et al. describen el algoritmo de *back propagation*⁷ para MLP
- **1989:** Se demuestra que un perceptrón multicapa (MLP) se comporta como **aproximador universal**⁸
 - Una única capa oculta es capaz de aproximar cualquier función continua de n variables
 - Pero **el número de parámetros puede terminar siendo extremadamente alto**
 - **Más capas** requieren **menos parámetros** y **aumentan** su capacidad de **generalización**
- **1998:** LeCun et al. aplican *back propagation* a redes convolucionales (CNN)

⁶ Fukushima, K. (1980). *Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position*. Biological cybernetics, 36(4), 193-202.

⁷ Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). *Learning representations by back-propagating errors*. nature, 323(6088), 533-536.

⁸ Cybenko, G. (1989). *Approximation by superpositions of a sigmoidal function*. Mathematics of control, signals and systems, 2(4), 303-314.

Comienza la era del aprendizaje profundo

- **2006:** G. Hinton acuña el término de *deep learning*⁹
- **2011:** IBM Watson gana en el concurso Jeopardy (markoff2011computer)
- **2012:** AlexNet gana el ImageNet, revolucionando el campo de la visión artificial¹⁰
 - A partir de este momento, **solo los algoritmos de DL ganan el concurso**
- **2014:** Facebook desarrolla DeepFace¹¹; Google compra [DeepMind](#)
- **2015:** ResNet¹² supera al humano en el ImageNet Contest

⁹ Hinton, G. E., & Salakhutdinov, R. R. (2006). *Reducing the dimensionality of data with neural networks*. science, 313(5786), 504-507..

Resolvieron el problema de *vanishing gradients* usando un proceso iterativo con *autoencoders* en las primeras capas.

¹⁰ Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). *Imagenet classification with deep convolutional neural networks*. Advances in neural information processing systems, 25. Arquitectura de 8 capas con un **error del 15.3%**. El anterior ganador obtuvo un **26.2%** de error. El ser humano tiene un error aproximadamente el **5%**.

¹¹ Taigman, Y., Yang, M., Ranzato, M. A., & Wolf, L. (2014). *Deepface: Closing the gap to human-level performance in face verification*. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 1701-1708).

¹² He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep residual learning for image recognition*. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 770-778).

La era contemporánea

- **2016:** [Alpha Go](#) (Google DeepMind) vence a Lee Sedol
 - Aprendizaje por refuerzo preentrenado con datos de humanos
- **2017:** [Alpha Go Zero](#) vence a Alpha Go
 - El salto es sustancial, ya que **no se preentrena con datos humanos**
- **2018:** [Alpha Star](#) vence al mejor jugador de Startcraft II
 - Su primera versión logró colarse entre el 0.2% de los mejores jugadores del mundo
- **2019:** [GPT-2](#) (OpenAI); modelo de lenguaje con 1.5 billones de parámetros
- **2021:** [DALL-E](#) (OpenAI); modelo de generación de imágenes a partir de texto
- **2023:** [MusicGen](#); modelo de generación de música (basado en GPT-3)¹³
- **2024:** [SORA](#) (OpenAI); modelo de generación de video a partir de texto¹⁴

¹³ Copet, Jade, et al. *Simple and controllable music generation*. *Advances in Neural Information Processing Systems*, 2024, vol. 36.; > Web <https://musicgen.com/> (último acceso 19 de febrero de 2024).

¹⁴ Informe técnico: Video generation models as world simulators; Web: <https://openai.com/sora> (último acceso 19 de febrero de 2024).

El porqué de su popularidad

Razones

En una palabra: **exactitud** (*accuracy*)

- El DL logra una precisión como nunca antes alcanzada
- Los modelos llegan a superar a los humanos en algunas tareas

Teorizado a mediados de los 1980, pero ahora es útil porque disponemos de:

1. Cantidades ingentes de datos y la posibilidad de almacenarlos
2. Acceso a una gran potencia de cálculo y técnicas para optimizarlo

Algunos autores y denominan **aprendizaje universal** al DL

- Se debe a que es una técnica útil para casi todos los campos de aplicación
- El **transfer learning** ayuda a esta concepción de la universalidad

Preprocesamiento de datos (I)

El ML necesita de una fase de extracción e ingeniería de características

- El DL no, sólo requiere de la adaptación de los datos de entrada al modelo

Necesitamos preparar los datos para representarlos

- **Muy** complejo, requiere **mucho conocimiento del dominio**
- Proceso de ensayo y error para obtener resultados óptimos

En DL no es necesario un paso de preprocesamiento de datos

- El modelo aprende a representar los datos brutos por sí misma
- Cada capa aprende una representación cada vez más abstracta
- Se optimiza automáticamente durante el entrenamiento

Preprocesamiento de datos (II)



Figura 6. Un proceso de aprendizaje automático requiere una fase de selección de características.



Figura 7. El aprendizaje profundo no requiere de dicha fase, ya que el propio modelo es capaz de inferir las características relevantes para el problema en cuestión.

Big data

Los modelos de ML tradicional dejan de mejorar a partir de un punto

- **Punto de saturación**, donde la precisión ya no mejora añadiendo más datos

Los algoritmos de DL son menos sensibles al punto de saturación

- Añadir más datos tiende a producir una mejora en la exactitud (*accuracy*)
- En la era del **Big Data** es una gran ventaja
 - Nunca hemos tenido tantos datos disponibles ni tanta capacidad de cómputo como ahora

Los algoritmos de DL escalan en términos de datos y, sobre todo, de cómputo

- Por ejemplo, ResNet se implementó a escala de supercomputación
- Se ha demostrado que el DL puede escalar a cientos de miles de núcleos

Big data



Figura 7. Relación entre capacidad de aprendizaje y volumen de datos en modelos estadísticos, de aprendizaje automático y de aprendizaje profundo (redes neuronales).

Ventajas y desventajas del aprendizaje profundo

Ventajas

- Capacidad de **aprender y adaptarse** (mejorar) de forma independiente
- **Aplicable** en casi cualquier campo y **sobre cualquier problema**
- **Superación de la capacidad humana** en tareas específicas
- **Revolución en múltiples sectores** (medicina, automoción, finanzas, etc.)

Inconvenientes

- Necesidad de **muchos datos**
- Altísimo **coste computacional** y por tanto, **impacto medioambiental**
- Prácticamente **imposible interpretar o explicar** los modelos generados
- Riesgo de **perpetuación de sesgos existentes** en los datos de entrenamiento

Areas de aplicación

Áreas de aplicación del aprendizaje profundo

Hemos visto que al DL se le suele denominar «método de aprendizaje universal»

- Esto es porque es potencialmente aplicable a todos los campos
- De hecho **hoy en día se aplica a casi todos los campos conocidos**

Usados normalmente donde se requieren habilidades humanas

- Por ejemplo, la visión, reconocimiento del habla o del entorno
- Y no hay disponible un humano para realizar las tareas
 - O lo hay, pero sería tremendamente ineficiente ... o imposible

A continuación veremos algunos ejemplos de aplicaciones del DL



Robótica (I)

Una de las áreas en las que el DL ha tenido más impacto

- Percepción de obstáculos y path planning inmediato
- Tareas de estabilidad y control¹⁵
- Robots industriales con visión artificial
- Apoyo a sistemas de mantenimiento predictivo
- Asistencia a la comunicación intra e inter-robot
- Robótica de servicio y asistencial

¹⁵ Los robots de Boston Dynamics, hasta cayéndose lo hacen con estilo. Imagen extraída de <https://youtu.be/aX7KypGlitg> (The Independent)

Robótica (II)

Los coches autónomos son una de las tecnologías en auge gracias al DL

- Detección y seguimiento de objetos alrededor del vehículo¹⁶
- Ubicación en la calzada
- Identificación de las señales de tráfico
- Análisis en tiempo real del estado del conductor o del vehículo
- Asistencia a la comunicación intra e inter-vehicular

¹⁶ Imagen extraída de Zheng, Jingxiao, et al. *Multi-modal 3d human pose estimation with 2d weak supervision in autonomous driving*. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022. p. 4478-4487.



Texto y lenguaje

El DL es ideal para las tareas de NLP

- Las herramientas que lo usan son órdenes de magnitud más avanzadas
- Aprovecha muy bien la habilidad del DL para extraer características

Algunas aplicaciones dentro del área incluyen:

- Entender la actitud de un actor mediante el análisis del lenguaje usado¹⁷
- Filtrado de información en función de parámetros sociales, geográficos, económicos y preferencias individuales¹⁸
- Generación de texto en lenguaje natural desde información no estructurada¹⁹

¹⁷ Ejemplo: <https://monkeylearn.com/sentiment-analysis-online/>

¹⁸ Ejemplo: <https://www.facebook.com/Engineering/videos/10154132641047200>

¹⁹ Ejemplos: <https://play.aidungeon.io>, <https://www.projectelectricsheep.com/> o <https://www.usetopic.com/blog-idea-generator>

Visión artificial

El *deep learning* permite el reconocimiento visual de imágenes a gran escala

- Abstrae prácticamente todo esfuerzo manual en el proceso
- Permite identificar características en grandes conjuntos de datos
- En definitiva, está impulsando el crecimiento de muchas áreas
 - Es esencial en todo sistema que requiera visión (p.ej. coches autónomos)
 - Segmentación de tumores cerebrales²⁰
 - Sistemas de reconocimiento de expresión facial²¹
 - Reconocimiento biométrico a través del iris del ojo. Deeplris²²

²⁰ Ranjbarzadeh, Ramin, et al. *Brain tumor segmentation of MRI images: A comprehensive review on the application of artificial intelligence tools*. *Computers in biology and medicine*, 2023, vol. 152, p. 106405.

²¹ Hassan, Syed Muhammad, et al. *An Effective Combination of Textures and Wavelet Features for Facial Expression Recognition*. *Engineering, Technology & Applied Science Research*, 2021, vol. 11, no 3, p. 7172-7176.

²² Tamizhiniyan, S. R., et al. *Deeplris: An ensemble approach to defending Iris recognition classifiers against Adversarial Attacks*. *En 2021 International Conference on Computer Communication and Informatics (ICCCI)*. IEEE, 2021. p. 1-8.

Asistentes virtuales

Son aplicaciones que entienden los comandos en lenguaje natural

- Amazon Alexa, Cortana, Siri, Google Assistant, ...
- Personalizan la experiencia de usuario en base al histórico
- Aprenden con cada interacción, sobre todo en reconocimiento
- Otras capacidades: Traducción de discurso a texto, toma de notas, gestión de citas

Los *chatbot* (p.ej. ChatGPT) son asistentes virtuales específicos para chatear

- Interacción con clientes y marketing en las redes sociales
- Ofrecen atención al cliente inmediata y personalizada
- Algunos ejemplos:
 - [Andy Robot](#), *chatbot* para aprender inglés en Telegram
 - Alerta de Salud de la OMS: WhatsApp al +41 797 818 791 con 'Hi'

Salud

Una de las mayores tendencias actuales es en el área de la salud²³

- En el área de la atención sanitaria
 - Ayuda al diagnóstico por rayos X (waheed2020covidgan,narin2021automatic)
 - Análisis en tiempo real de datos agregados de sensores (philip2021deep)
 - Diagnósticos y tratamientos personalizados por paciente (oh2021deep)
 - Identificación de trastornos del desarrollo como el autismo~ (heinsfeld2018identification)
- En el área farmacéutica
 - Descubrimiento de fármacos (predicción de sus efectos) (gawehn2016deep,chen2018rise)

²³ Piccialli, Francesco, et al. Artificial intelligence and healthcare: Forecasting of medical bookings through multi-source time-series fusion. Information Fusion, 2021, vol. 74, p. 1-16.

Generación de contenido

Otra de las áreas es la modificación o generación total de contenido

- [WaveNet](#) analiza y sintetiza señales de audio similares (oord2016wavenet)
- AutoFoley crea efectos de audio a partir de vídeos mudos (ghose2020autofoley)
- [NeuralFunk](#) genera pistas de audio de longitud indefinida
- Generación de rostros realistas pero inexistentes (karras2017progressive)
- Generación de los momentos más destacados en competiciones, p.ej. Wimbledon (merler2018automatic)
- Vídeos e imágenes «ultrafalsas» (thies2016face2face)
- [DeepDream](#) genera imágenes psicodélicas a partir de su conocimiento

Y muchas más áreas

- Ciberseguridad
- Realidad virtual y aumentada
- Simulación y videojuegos
- Ciencias sociales
- Finanzas y bolsa

Limitaciones y retos

Limitaciones y retos de los modelos de *deep learning* (I)

Los requisitos de hardware

- Los modelos requieren cada vez más memoria y capacidad de cómputo
- Las GPU y TPU son muy caras, además del impacto energético y medioambiental

Los modelos más potentes usan cada vez más parámetros

- Esto es, cada vez conjuntos de datos más grandes, que no siempre tenemos
- A veces se emplean en datos sintéticos, pero no siempre es válido usarlos

Los modelos, una vez entrenados, se vuelve inflexibles

- Soluciones eficientes, pero para problemas concretos
- Es muy típico que un problema similar requiera de un nuevo entrenamiento

Limitaciones y retos de los modelos de *deep learning* (II)

Los modelos de *deep learning* aprenden mediante observaciones

- Solo saben lo que existe en los datos con los que se ha entrenado
- Una muestra no representativa hace que el modelo no generalice

Los datos suelen estar sesgados (consciente o inconscientemente)

- Si existen sesgos en los datos, existirán en las predicciones
- Los modelos aprenden a partir de variaciones que, a veces, no son explícitas
- Una decisión errónea/poco ética puede impactar negativamente en el mundo real
- No existe (por ahora) forma clara de explicar el razonamiento tras cada predicción
 - La imposibilidad de explicación hace todavía más difícil detectar estos problemas de sesgo

Inteligencia artificial explicable (XAI, del inglés *explainable AI*)

¿Cuál es el problema de la XAI?

Los modelos funcionan como una caja negra

- Aprenden relaciones y razonan a través de ellas
- Estas tienen poco o nada que ver con el razonamiento humano
 - No entraremos en el debate de si este es o no simbólico
- Aun errónea, no sabríamos el porqué ni cómo contraargumentar una decisión

Estas decisiones pueden tener un **impacto social o medioambiental**

- Diagnóstico médico donde se determina una enfermedad
- Concesión o no de un crédito en función de ciertos parámetros
- Emisión de veredictos judiciales
- Frenar o no ante humanos en un paso de peatones

Sobre la inteligencia artificial explicable

Es el conjunto de técnicas y métodos para explicar las decisiones de algoritmos de IA, teniendo en cuenta:

1. Naturaleza del modelo, que comprende dos extremos
 - Modelos totalmente transparentes como los árboles de decisión
 - Modelos de caja negra como Artificial Neural Network (ANN)
2. Público objetivo, que afecta en dos dimensiones diferentes
 - Nivel de detalle
 - Forma de presentación

Conclusiones

Conclusiones

El aprendizaje profundo se utiliza extensivamente en la industria

- Cada vez más organizaciones lo están adoptando para seguir siendo competitivas

En la última década ha habido un gran avance en el DL, principalmente por:

- La amplia disponibilidad del *big data*,
- La potencia computacional, y
- Nuevas técnicas que han mejorado los modelos convencionales en varios órdenes de magnitud

Aun así, hay muchas aplicaciones a las que no se debería delegar las decisiones debido a su potencial impacto en la vida de las personas

Licencia

Esta obra está licenciada bajo una licencia **Creative Commons
Atribución-NoComercial-CompartirIgual 4.0 Internacional**.

Puedes encontrar su código en el siguiente enlace:
<https://github.com/blazaid/aprendizaje-profundo>